

Sistema RAG Distribuído — Documento Técnico (Tema 5)

- **Disciplina:** Engenharia de Contexto e Harness Engineering aplicada à Programação Distribuída e Paralela
 - **Tema:** 5 — Sistema de Q&A com Retrieval-Augmented Generation (RAG) distribuído em 3 PCs físicos, sem custos de cloud
 - **Instituição / período:** CESUPA, 2.º bimestre de 2026 — entrega 2026-06-01 (prorrogada de 2026-05-25)
 - **Equipe (trilhas):** **A** = Davi Cavalcante (autor; PC1 pc1-davi, GPU NVIDIA RTX 4060 Ti) · **B** = Pablo Abdon (PC2 abdon-workstation) · **C** = João Miguel (PC3 pc2-jm)
 - **Repositório:** este, raiz; código em src/, infraestrutura em infra/, prompts em prompts/, planos em docs/superpowers/
-

Resumo executivo

Sistema de Q&A com RAG distribuído entre três PCs físicos via Tailscale, sem cloud. Indexa corpus PT-BR sobre engenharia de software, atende consultas com citações rastreáveis e demonstra **paralelismo em duas dimensões**: dados na ingestão (fila de documentos → N chunk-workers) e tarefas no atendimento (query-workers replicados). A engenharia de contexto é explícita (chunking recursivo, retrieval em dois estágios, prompts versionados, function calling); a observabilidade cobre métricas (Prometheus), logs (Loki) e dashboards (Grafana); a tolerância a falhas atravessa quatro camadas (retry, DLX/DLQ, degraded mode, fallback estrutural). A infraestrutura é descrita como código (Terraform + Ansible). Medido em Modo 1 (single-host PC1): 122 chunks indexados de um PDF de 169 páginas, respostas com 3 citações em ~2.1 s (cache) e ~14 s (cold).

1. Introdução

1.1 Problema e objetivos

O problema atacado é o de **resposta fundamentada a perguntas sobre um corpus**: dado um conjunto de documentos (PDF, Markdown, HTML), o sistema precisa receber uma pergunta em linguagem natural, recuperar trechos pertinentes do corpus e gerar uma resposta sintética que cite as fontes. Ao contrário de um chatbot genérico, o sistema **não deve responder a partir de conhecimento paramétrico do modelo** quando o corpus não cobre a pergunta — deve declarar a ausência de fundamento. O modelo gerador (qwen2.5:7b-instruct) é instruído explicitamente a responder apenas pelos blocos de contexto entregues.

Os objetivos do trabalho são quatro: (i) demonstrar **distribuição real** (não simulada) entre três máquinas físicas conectadas por uma rede privada (Tailscale); (ii) implementar **engenharia de contexto explícita** — chunking, re-ranking, prompts versionados, function calling, gestão de histórico — cobrindo o requisito 4.3 do enunciado; (iii) **observar e tolerar falhas** com métricas, logs correlacionados e degradação controlada; (iv) **descrever a infraestrutura como código** para que a topologia distribuída seja reproduzível a partir do repositório.

1.2 Decisão de não usar cloud

O enunciado da disciplina cita serviços de nuvem (SQS, S3, DynamoDB, CloudWatch) como referência. A equipe optou por executar inteiramente em ambiente local, mapeando cada serviço de cloud a um equivalente self-hosted: **SQS → RabbitMQ**, **S3 → volumes Docker**, **DynamoDB → Redis (cache) e Qdrant (vector store)**, **CloudWatch → Prometheus + Grafana + Loki**. A decisão foi tomada por três razões: (i) custo zero compatível com a disciplina; (ii) demonstrar que o sistema é portátil entre PCs comuns ligados por uma VPN; (iii)

controle total sobre a topologia, necessário para os experimentos de paralelismo e tolerância a falhas.

1.3 Mapa de requisitos do enunciado

Requisito do enunciado	Onde foi atendido
4.1 Paralelismo de dados	ingest-worker-chunk replicado (N consumidores de ingest.chunks); ver §3.1 query-worker replicado; ver §3.2 RabbitMQ + DLX rag.dlx + *.dlq; ver §5.2 Chunking, retrieval+rerank, prompts versionados, function calling, sessão; ver §4. Function calling com ressalva de adesão documentada em §4.6 e §8.1
4.1 Paralelismo de tarefas	
4.2 Mensageria com DLQ	
4.3 Engenharia de contexto	
4.4 Observabilidade	11 métricas Prometheus em src/shared/metrics.py; dashboard infra/grafana/dashboards/rag-distribuido.json; logs JSON via structlog indexados por Loki; ver §2.4 e §5.3
4.5 Tolerância a falhas	Retry tenacity, DLX/DLQ, degraded mode no gateway, fronteira de erro por chunk; ver §5
4.6 IaC	Terraform (provider kreuzwerker/docker) + Ansible (bootstrap + deploy); ver §6
8.1 Repositório Git	Este repo
8.2 Documento técnico	Este documento
8.3 Apresentação	A entregar em 2026-05-25
8.4 Relatórios individuais	docs/relatorios_aprendizagem/{davi_cavalcante,joao_mi
Bônus +10 (vLLM)	Cortado por cronograma; ver §8.4

2. Arquitetura

2.1 Componentes

O sistema é composto por nove serviços, hospedados em três PCs ligados por Tailscale. O PC1 é o **servidor** (gateway HTTP, mensageria, vector store, cache, GPU, observabilidade); PC2 e PC3 são **workers** (consumidores das filas de ingestão e de query). A figura abaixo apresenta a topologia em forma de grafo de componentes:




Figure 1: Diagrama de componentes — PC1 concentra servidor (gateway HTTP, RabbitMQ, Qdrant, Redis, Ollama com GPU, rerank-service) e a stack de observabilidade; PC2 e PC3 hospedam workers (ingest-worker-doc, ingest-worker-chunk, query-worker) e Promtail local. Setas pontilhadas representam fluxos passivos de observabilidade (scrape Prometheus, push Loki).

O **gateway** (src/gateway/) é o único ponto HTTP do sistema: expõe POST /ingest, POST /query, GET /health e GET /metrics. Não toca diretamente Qdrant ou Ollama no caminho feliz —

publica nas filas e aguarda resposta via RPC sobre AMQP (§3.2). No caminho degradado (timeout do worker de query), o gateway acessa Qdrant e Ollama diretamente para devolver chunks brutos com a marca [degraded mode] (§5.3).

Os **workers de ingestão** estão divididos em duas funções, definidas pela variável de ambiente `INGEST_ROLE`: o `ingest-worker-doc` faz `parse` → `chunk` (CPU-leve) e publica os chunks na fila `ingest.chunks`; o `ingest-worker-chunk` faz `embed` → `upsert` (IO/GPU-carro). A divisão permite escalar cada estágio de forma independente — tipicamente um `doc-worker` é suficiente para alimentar N `chunk-workers` (§3.1, §8.2 do relatório de Davi). O `query-worker` (`src/workers/query/`) consome `query.requests`, percorre o pipeline de 7 fases (§3.2) e publica a resposta na fila exclusiva de retorno.

O **rerank-service** (`src/rerank_service/`) é um FastAPI standalone que hospeda o cross-encoder BAAI/bge-reranker-v2-m3 (sentence-transformers). É isolado dos workers por dois motivos: o modelo ocupa ~600 MB em RAM (replicar em cada worker desperdiça memória) e centralizar permite trocar CPU por GPU sem mexer no resto do pipeline (§7.2 do relatório de Davi).

2.2 Topologia distribuída via Tailscale

O Tailscale forma uma mesh WireGuard entre os três PCs, exposta como rede 100.x.y.z/24 privada. A escolha não é meramente de conveniência: os serviços do PC1 (Redis, Qdrant, Ollama) **não têm autenticação habilitada** — expô-los à internet seria inseguro, mas dentro da tailnet privada do trio o risco é controlado. Durante o B3, a equipe descobriu uma pegadinha relevante: o domínio `@aluno.cesupa.br` agrupa toda a turma num mesmo tailnet automaticamente, então autenticar com a conta institucional jogaria os PCs no tailnet compartilhado. A saída foi criar um tailnet dedicado com identidade pessoal não-CESUPA; o procedimento está documentado em `docs/setup-tailscale.md`.

Uma medição empírica importante: `tailscale ping --direct` entre `pc1-davi` e `pc2-jm` retornou **~113 ms** de latência. Este número é o piso para todo round-trip worker → PC1 (embedding, retrieval, hop AMQP) e está embutido em todos os experimentos do B4 (§7).

2.3 Modo 1 vs Modo 2

O sistema opera em dois modos a partir do **mesmo** `docker-compose.yml`, diferenciados por *profiles* Compose:

- **Modo 1** (single-host, profile `all`): toda a stack sobe num único PC, com DNS interno do Compose (`rabbitmq:5672`, `qdrant:6333`, ...). Usado para desenvolvimento e para o `make smoke` do B1/B2.
- **Modo 2** (distribuído, profiles `server` e `worker`): PC1 sobe `server` (gateway + infraestrutura + observabilidade); PC2/PC3 sobem `worker` (apenas os consumidores). As URLs trocam de DNS interno para IPs Tailscale via `.env.local` gerado pelo Ansible (§6.2).

A separação por profile é a única alteração necessária para fazer o sistema rodar em três hosts em vez de um — toda a lógica de aplicação (publicar, consumir, embedar, upsertar) é idêntica.

2.4 Stack de versões pinadas

Componente	Imagem / pacote	Versão
Runtime	Python (uv) + FastAPI/Uvicorn	3.12
Mensageria	<code>rabbitmq:3-management</code> (+ <code>rabbitmq_prometheus</code>)	3.x

Componente	Imagem / pacote	Versão
Vector store	qdrant/qdrant	v1.12.4
Cache / sessão	redis:7-alpine	7.x
LLM serving	ollama/ollama	0.23.2
LLM gerador	qwen2.5:7b-instruct	7B, num_ctx 8192
Embeddings	nommic-embed-text	768d, max 2048 tokens
Re-ranker	BAAI/bge-reranker-v2-m3	cross-encoder, max 512
Observabilidade	Prometheus 2.55.1, Grafana 11.4.0, Loki/Promtail 3.2.0	—
IaC	Terraform (kreuzwerker/docker) + Ansible	—

3. Fluxos

3.1 Ingestão — pipeline de duas filas (paralelismo de dados)

A ingestão é dividida em dois estágios encadeados por filas RabbitMQ. A divisão não é organizacional; é arquitetural — os dois estágios têm perfis de custo opostos, e duas filas permitem afinar o paralelismo de cada um separadamente.




Figure 2: Sequência da ingestão — pipeline parallelism em duas filas. O ingest-worker-doc faz parse + chunk + publish (loop por chunk); N ingest-worker-chunk consomem em paralelo (par) fazendo embed no Ollama e upsert no Qdrant.

O **doc-worker** consome ingest.documents, parseia o PDF página a página (pypdf), detecta idioma (langdetect) e aplica o splitter recursivo (§4.1). Para cada chunk produzido, publica uma ChunkMessage em ingest.chunks carregando o correlation_id original via header AMQP. O chunk_index não vai no schema; viaja pelo cabeçalho AMQP correlation_id (uma escolha deliberada — manter o schema enxuto).

O **chunk-worker** consome ingest.chunks com prefetch=8, chama o Ollama para gerar o embedding (nomic-embed-text, 768 dimensões) e faz upsert no Qdrant. O point_id no Qdrant é derivado deterministicamente de $\text{int}(\text{sha256}(\text{chunk_id}), 16) \% (2^{63} - 1)$. Isso torna o

upsert **idempotente**: reenviar o mesmo documento (retry, replay de DLQ, colega reprocessando) sobrescreve os mesmos pontos em vez de duplicar o corpus.

Fronteira de erro por chunk. Falhas isoladas no Ollama (chunk grande demais, status 500 em nomic-embed-text por estourar max_length=2048) são absorvidas pelo chunk-worker: o chunk problemático é pulado com log.warning("ingest.chunk.skipped", ...) e a indexação prossegue. Já erros de conexão (httpx.TransportError) propagam — se o Ollama está fora, pular não faz sentido (todo chunk falharia). Esta granularidade está documentada no §2.15 do relatório de Davi.

3.2 Atendimento de query — RPC sobre AMQP + 7 fases

O /query do gateway implementa um padrão **RPC sobre mensageria**: HTTP request/response síncrono no exterior, mas fire-and-forget assíncrono no interior. O gateway cria uma fila exclusiva de retorno query.responses.{correlation_id}, publica a pergunta em query.requests com reply_to=<nome da fila exclusiva>, e itera nela com timeout de 120s. O worker lê o reply_to e responde exatamente nessa fila. Cada query simultânea tem isolamento total: como a reply queue é exclusive=True, auto_delete=True, ela morre quando o channel fecha — não há possibilidade de dois requests pegarem a resposta um do outro.




Figure 3: Sequência da query — RPC sobre AMQP com reply queue exclusiva por correlation_id e as 7 fases do handle_query no worker: (1) embed com cache L1, (2) retrieval top-20 no Qdrant, (3) rerank top-5, (4) lookup do cache L2, (5) montagem com preâmbulo de sessão, (6) generation com function calling, (7) append na sessão + publish.

As **7 fases** do handle_query são implementadas em src/workers/query/main.py e estão in-

strumentadas por fase no histograma `rag_query_pipeline_duration_seconds{phase}`, o que permite identificar onde está o gargalo de qualquer query no dashboard Grafana (painel 2). As fases 1 e 4 são *cache-aside* (consulta o cache antes da chamada cara; popula no miss); a fase 4, em particular, fica **depois** do rerank porque a chave do L2 é `sha(query + retrieved_ids)`, e os `retrieved_ids` só existem depois do rerank ter rodado — consequência arquitetural discutida em §8.3.

4. Engenharia de contexto

Esta seção cobre o requisito 4.3 do enunciado. A engenharia de contexto é o conjunto de decisões — chunking, retrieval+rerank, prompts, orçamento de tokens, cache, sessão, function calling — que governam **o que o modelo vê** quando precisa responder. Como o modelo gerador não foi treinado no corpus, o prompt é o único canal; cada decisão abaixo controla densidade, fidelidade ou alcance desse canal.

4.1 Chunking recursivo com fronteiras semânticas

O `chunk_text` (`src/workers/ingest/chunking.py`) implementa um *recursive character splitter*: tenta quebrar primeiro em parágrafos (`\n\n`), depois em linhas (`\n`), depois em frases (`.`), depois em palavras (); apenas como último recurso aplica corte arbitrário por caractere. A intuição é que quebrar entre parágrafos preserva coerência, enquanto cortar no meio de uma frase mutila o significado — a recursão é o mecanismo que tenta o “menos invasivo” primeiro.

Os parâmetros são `target_tokens=800` (preferência de tamanho, otimizada para retrieval de granularidade média) e `overlap_tokens=120` (~15%, redundância barata para garantir que uma frase que cai exatamente na fronteira entre chunks apareça inteira em pelo menos um deles). Um terceiro parâmetro foi adicionado durante o B1 como **teto duro**: `max_tokens=2048`, igual ao limite de input do `nomic-embed-text`. Sem esse teto, chunks vindos de PDFs densos em PT-BR estouravam o limite do embedder porque a heurística `count_tokens_approx` (`chars ÷ 4`, copiada da regra de inglês com BPE) subestima sistematicamente português tokenizado por WordPiece. O dimensionamento correto passou a ser `min(target_tokens, max_tokens) × 4` em `char-space` (§2.15 do relatório de Davi).

4.2 Retrieval em dois estágios

A recuperação é feita em dois estágios encadeados:

1. **Bi-encoder (top-20)** — embedding da query no espaço 768d do `nomic-embed-text`; busca por similaridade cosine no Qdrant. Barato porque os embeddings dos documentos são pré-computados na ingestão.
2. **Cross-encoder (top-5)** — os 20 candidatos são re-ranqueados pelo `bge-reranker-v2-m3` via `POST /rerank` no `rerank-service`. O cross-encoder concatena query + candidato como entrada única e roda atenção cruzada sobre o par — mais preciso porque vê a interação entre os tokens, mas mais lento (cada par exige um forward pass dedicado).

A ordem é forçada pela natureza dos modelos: passar os centenas de milhares de chunks do corpus pelo cross-encoder seria proibitivo; o bi-encoder serve para reduzir o espaço a 20 candidatos, sobre os quais o cross-encoder consegue rodar em tempo aceitável (~8 s em CPU sobre 20 candidatos com `bge-m3`).

4.3 Prompts versionados

Os prompts vivem em `prompts/`, fora do código, em arquivos `.md` com frontmatter YAML (`version`, `model_target`, `last_changed`, `notes`). São três: `system_qa_pt.md`, `system_qa_en.md` (políticas: responder apenas pelo contexto, formato de citação [`doc_id: ...`, `page: ...`])

como fallback e tool `cite_source` como primário), e `user_qa_template.md` (Jinja2 com `{question}` e `{context_blocks}`). O carregamento usa um *prompt registry* simples que abstrai a leitura do arquivo, remove o frontmatter e retorna o texto puro; o `build_prompt` (`src/workers/query/prompt_builder.py`) seleciona o system por idioma da query e renderiza o user.

A versão atual é **v0.2.3-b2**, resultado de quatro iterações durante o fechamento do B2 (§8.12 do relatório de Davi): v0.2.0 (formato híbrido tool + fallback textual), v0.2.1 (imperativo na regra de citação), v0.2.2 (remoção do escape do fallback textual no prompt), v0.2.3 (exemplo few-shot). O bump de versão e o espelhamento `pt` → `en` foram declaradamente delegados à IA na entrada de 2026-05-22 do `US0_DE_IA.md`.

4.4 Orçamento de tokens e truncamento

A janela do `qwen2.5:7b` é configurada com `num_ctx=8192`. O `build_prompt` reserva ~1500 tokens para system + pergunta + resposta esperada, deixando ~6500 para os blocos de contexto. Quando os 5 chunks reranqueados ultrapassam esse orçamento, o `build_prompt` **trunca a cauda** dos blocos — o retrieval entrega rankeado por score, então a cauda é o material menos relevante. Cortar deliberadamente a cauda é melhor do que deixar o runtime do Ollama cortar o fim do prompt (que muitas vezes inclui a própria pergunta).

4.5 Cache distribuído L1 e L2 + sessão

O Redis serve dois caches e o store de sessão:

- **L1** (`emb:{sha(query)}`, TTL 7d) — vetor 768d da query; hit dispensa Ollama na fase 1.
- **L2** (`resp:{sha(query + retrieved_ids)}`, TTL 1h) — resposta inteira; a chave depende do output do rerank, então o L2 fica **pós-rerank**: hit pula geração (~26 s) mas paga embed + retrieval + rerank (~8 s). No smoke estendido, 2ª execução caiu de 14.4 s para 8.4 s (~58 %) — trade-off “correção da chave” sobre “economia máxima” (§8.3).
- **Sessão** (`session:{sid}:history/summary`, TTL 6h) — janela recente + resumo acumulado, gerado por summarizer injetável (Strategy/DI): default `concat_summarizer` (sem LLM); plugável para variante com `qwen2.5:7b` sem mexer na classe.

4.6 Function calling — `cite_source` (com ressalva)

A tool `cite_source(doc_id, page, snippet)` (`prompts/tools/cite_source.json`, formato Ollama/OpenAI) é a forma escolhida para estruturar citações: em vez de o modelo escrever `[source: x, page: 5]` em prosa (sujeito a regex frágil), ele chama a tool e o sistema recebe campos separados. O `OllamaClient.chat` envia `tools=[cite_source]`; o worker processa `tool_calls` na fase 6/7 e materializa cada chamada em `Citation`. Quando o modelo **não** chama a tool, o sistema cai num **fallback estrutural** — as citações são montadas direto a partir dos chunks injetados no prompt; a relação “chunks usados → citações” é correta nos dois caminhos.

A **ressalva**: o `qwen2.5:7b` não adere à tool sob contexto RAG denso. A análise completa do achado (diagnóstico isolado, hipóteses, alavancas remanescentes) está em §8.1.

5. Tolerância a falhas

A filosofia transversal é **degradar antes de quebrar**: em cada ponto onde algo pode dar errado, há uma escolha consciente entre absorver e propagar. As quatro camadas a seguir implementam essa filosofia em granularidades diferentes.

5.1 Retry com backoff exponencial (tenacity)

Todo client HTTP externo (OllamaClient, RerankerClient) é envolvido em um AsyncRetrying do tenacity com 3 tentativas, backoff exponencial com *jitter* e teto de 8 segundos. A configuração absorve soluções transitórias de rede (especialmente importantes no Modo 2, onde o piso de latência é ~113 ms) sem prender uma requisição por minutos. O `retry_if_exception_type` cobre `httpx.TransportError` e códigos 5xx; 4xx propagam imediatamente (erro do cliente, retry não ajuda).

5.2 DLX rag.dlx + DLQ por base + retry contado

`declare_topology (src/shared/messaging.py)` cria uma DLX `rag.dlx` (direct, durable) e, para cada base (`ingest.documents`, `ingest.chunks`, `query.requests`), uma DLQ `{base}.dlq` ligada por `routing_key=base` e a fila principal com `x-dead-letter-exchange/x-dead-letter-routing-key`. O `consume_forever` faz `ack/nack` manual e conta tentativas no header `x-attempts`: se falhar e `attempts >= 3`, faz `reject(requeue=False)` (cai na DLX → DLQ, inspecionável via `scripts/dlq_inspector.py`); caso contrário, republica cópia com `x-attempts` incrementado e dá `ack` na original. O teste `tests/integration/test_dlq.py` valida o fluxo completo (3 nacks → DLQ) em ~0.6 s contra um RabbitMQ real.

5.3 Degraded mode no gateway

Quando o `query-worker` não responde dentro de 120s (worker fora, fila atolada, geração travada), o gateway captura `TimeoutError` na espera da `reply queue` e entra em **modo degradado**: faz `embedding` direto via `app.state.ollama`, faz `query_points` no Qdrant via `app.state.qdrant` (sem `rerank`), monta as `Citation` a partir dos `hits` brutos e devolve `answer="[degraded mode] sem síntese; veja as citações abaixo."` com `usage={tokens_in: 0, tokens_out: 0}` e `latency_ms` medido com `time.perf_counter()` desde o início do handler.

A motivação é prática: numa apresentação ao vivo, devolver `chunks` brutos com a marca explícita é melhor do que devolver 504 Gateway Timeout vazio. O usuário vê material relevante (os `chunks` são exatamente os mesmos que a síntese usaria), com aviso claro de que a síntese falhou. A camada também emite a métrica `rag_errors_total{service="gateway", error_type="query_timeout"}` e o log estruturado `query.degraded.{starting, responded, failed}`, fechando o par evento+série temporal.

5.4 Fronteira de erro por chunk e fallback estrutural de citação

Dois camadas mais finas completam a filosofia: o `chunk-worker` absorve falhas isoladas no Ollama (chunk muito grande) pulando o chunk e seguindo o documento (§3.1); o `query-worker` absorve a não-adesão do modelo ao function calling caindo no caminho estrutural de citação (§4.6). Em ambos os casos, o sistema “perde uma camada” mas continua entregando valor.

6. IaC e topologia

6.1 Modo 1 com Docker Compose

O `docker-compose.yml` na raiz contém **toda a stack** (12 serviços com observabilidade) e usa `profiles` para diferenciar Modo 1 e Modo 2. Em Modo 1, `docker compose --profile all up -d` sobe tudo num só host; o `Makefile` empacota isso em `make dev`. Volumes nomeados (`rabbitmq_data`, `qdrant_storage`, `redis_data`, `ollama_models`, `prometheus_data`, `grafana_data`, `loki_data`) persistem estado entre `down/up`.

6.2 Modo 2 com Terraform + Ansible

A separação reflete responsabilidades diferentes (Ansible imperativo prepara hosts; Terraform declarativo gerencia containers):

- **Ansible** — `playbook-bootstrap.yml` instala Docker, Tailscale (todos) e NVIDIA Container Toolkit (só PC1). `playbook-deploy.yml` sincroniza o repo via rsync, renderiza `.env.local` a partir de `env.j2` com IPs Tailscale do inventário e dispara `terraform apply` em cada host.
- **Terraform** — `main.tf` instancia `modules/server` ou `modules/worker` por `var.host_role`. `server` declara RabbitMQ, Qdrant, Redis, Ollama, Gateway; `worker` declara os três consumers. Configuração por host em `envs/{pc1,pc2,pc3}.tfvars`.
- **Wrapper** — `scripts/deploy.sh` orquestra os dois playbooks.

6.3 GPU no PC1

O PC1 (Linux Mint 22.3, RTX 4060 Ti) precisa de três camadas para o Ollama acelerar geração e embedding na GPU: (i) driver proprietário NVIDIA (não o nouveau do kernel); (ii) NVIDIA Container Toolkit (`nvidia-container-toolkit` + reconfiguração do runtime do Docker); (iii) o serviço ollama no Compose com `deploy.resources.reservations.devices` apontando para `driver: nvidia`. O procedimento completo está em `docs/setup-gpu-pc1.md`, descoberto durante a Task 15 do B1 (§2.14 do relatório de Davi).

7. Resultados experimentais

Esta seção apresenta os resultados das medições já executadas (B1/B2) e descreve o protocolo dos experimentos que dependem da infraestrutura distribuída completa (B4).

7.1 Smoke B1 (Modo 1, 2026-05-18)

Cenário: PC1 com Compose Modo 1, 1 ingest-worker fat (sem split em duas filas — esse split veio em B2), 1 query-worker, 1 PDF de 169 páginas em PT-BR (`ap_es_v1.pdf`).

Métrica	Valor
Chunks indexados	122
Chunks pulados pela fronteira de erro (> 2048 tokens)	~7
Tempo de query (cold)	2.1 s
Citações retornadas	3
Páginas citadas	10, 51, 107

A resposta foi factualmente fundamentada nos trechos do PDF (PDCA, definições de engenharia de software, normas ISO/IEC 12119 / 9001:2008). O smoke validou pipeline ponta-a-ponta: `parse` → `chunk` → `embed` → `upsert` → `embed query` → `retrieve` → `generate` → `citation`.

7.2 Smoke B2 estendido (Modo 1, 2026-05-22)

Cenário: PC1 com Compose Modo 1 completo (`gateway` + `rerank-service` + 2 ingest-workers especializados + `query-worker` + L1/L2 + sessão).

Métrica	Valor
Chunks indexados	123
Citações retornadas	3

Métrica	Valor
1ª query (cold)	14.4 s
2ª query (mesma pergunta, L1 hit + L2 hit)	8.4 s (~58 % do tempo cold)
Sessão (2 turnos no mesmo session_id)	preâmbulo histórico/resumo exercitado sem erro
Rerank /health	healthy
/metrics no gateway	11 séries rag_* populadas

A redução parcial no L2 hit (58 % em vez de próximo de zero) é resultado arquitetural: o L2 fica pós-rerank, então o hit pula a geração (~26 s) mas paga embed + retrieval + rerank (~8 s). A escolha favorece **correção da chave** sobre **economia de latência** (§8.3).

7.3 Experimentos pendentes (B4)

Protocolos definidos em docs/superpowers/plans/2026-05-09-tema5-b4-experimentos-doc.md; dependem do Modo 2 completo (3 PCs ativos). Como medem desempenho do pipeline (paralelismo, throughput, recuperação a falhas) e não qualidade de recuperação, o corpus mínimo versionado em samples/corpus/ já basta para exercitá-los:

- **Exp 1 — speedup de indexação:** variar N chunk-workers ($N \in \{1, 2, 4, 8\}$), plotar tempo(N) e speedup(N)=T(1)/T(N). Saída: data/exp1/exp1.png.
- **Exp 2 — throughput de queries:** $C \in \{1, 2, 4, 8, 16, 32\}$ clientes simultâneos; medir QPS e p95. Saída: data/exp2/exp2.png.
- **Exp 4 — chaos test:** sob carga constante, derrubar (a) 1 chunk-worker, (b) Ollama, (c) rerank-service; medir taxa de erro e tempo de recuperação. Saída: data/exp4/exp4.png + log do chaos_test.sh.

Exp 3 (bônus +10, Ollama vs vLLM) cortado por cronograma em 2026-05-24. A entrega foi prorrogada de 2026-05-25 para 2026-06-01; até esta revisão (2026-05-31) os dados de Exp 1/2/4 **ainda não foram coletados** — a coleta depende do Modo 2 completo (3 PCs ativos via Tailscale), ainda pendente (§8.3). O dia adicional abre uma janela para coletar ao menos Exp 1/Exp 2 em Modo 1 (single-host), que não exigem a malha distribuída; persistindo a pendência de infraestrutura, os protocolos acima permanecem como contribuição metodológica e o resultado é declarado sem maquiagem.

8. Discussão e limitações

8.1 Function calling sob contexto RAG denso — o achado

Resultado negativo bem caracterizado, tratado como **achado**. O qwen2.5:7b-instruct foi exposto à tool cite_source em quatro versões de prompt (v0.2.0 híbrido → v0.2.1 imperativo → v0.2.2 sem escape textual → v0.2.3 com few-shot); em todas, 100 % das execuções caíram no fallback estrutural — nenhuma tool_call emitida. Um diagnóstico isolado (chamada direta a /api/chat com prompt de uma frase) confirmou que o modelo **chama** a tool com argumentos perfeitos — eliminando suspeitas sobre definição da tool, cliente Ollama ou capacidade do modelo.

A hipótese remanescente é que **a densidade do contexto suprime a chamada**: cinco chunks de ~800 tokens contra ~50 tokens de instrução dilui o sinal “use a ferramenta”; o viés de instruct-tuning empurra para prosa coerente; e a competição de formatos (cite_source(...) vs [doc_id: ...]) eleva a entropia da decisão. Forçar tool_choice="cite_source" (padrão OpenAI) seria a alavanca direta, mas **o Ollama não suporta esse parâmetro**. Alavancas não tentadas, candidatas a trabalho futuro: **passada dupla** (sintetizar + citar em chamadas sep-

aradas com contexto enxuto na segunda) e **decodificação restrita** via `format: json`. Ambas trocam latência por garantia de adesão.

Conclusão: o **requisito 4.3 está atendido** — function calling implementado, cabeado, com capacidade comprovada por diagnóstico isolado; a não-adesão sob contexto RAG denso é característica do modelo e da plataforma, não da implementação; o fallback estrutural garante citações corretas em qualquer caminho.

8.2 Limitações de modelagem

- **chars/4 para contagem de tokens** subestima PT-BR tokenizado por WordPiece. O back-stop real é a fronteira de erro do chunk-worker (captura `HTTPStatusError` quando o Ollama recusa). Um tokenizer real (e.g., tiktoken) eliminaria a heurística, ao custo de uma dependência.
- **L2 pós-rerank** paga rerank a cada hit (~8 s). Chavear por `sha(query)` só pularia o rerank, mas perderia “se o corpus muda, a chave muda” — trade-off deliberado (\$4.5).
- **Idempotência por posição, não por conteúdo.** `point_id` deriva de `chunk_id=f"{doc_id}:{chunk_index}"`. Reprocessar o mesmo PDF é idempotente, mas re-particionar gera ids novos mesmo com conteúdo coincidente. `sha256(text)` daria dedup por conteúdo ao custo de perder a ordem original.

8.3 Débitos técnicos conhecidos

- **_RedisLike duplicado** entre `cache.py` e `session.py` (cada módulo define seu `Protocol` mínimo). Consolidar em `src/shared/` eliminaria `redis_client: Any` na fronteira.
- **Smoke não-idempotente no L2:** rodar `make smoke` duas vezes mascara o teste (1ª query da 2ª rodada já é hit). Workaround: `redis-cli FLUSHALL` antes.
- **Modo 2 parcial:** PC2 confirmado via Tailscale; PC3 pendente. Os experimentos do B4 dependem dos três PCs ativos.

8.4 Escopo cortado deliberadamente

O **Exp 3 (Ollama vs vLLM, bônus +10)** foi o primeiro corte da lista de cortes pré-definida no `TOD0.md`, aplicado em 2026-05-24 por restrição de cronograma. O sistema continua íntegro sem ele; o que se perde é a comparação quantitativa entre o batching ingênuo do Ollama e o continuous batching do vLLM, que seria evidência adicional para a discussão de paralelismo no servidor de inferência.

9. Conclusão

O sistema cumpre os requisitos de 4.1 a 4.6 do enunciado e os entregáveis 8.1, 8.2, 8.4 e Extra. A distribuição é real: três PCs físicos, conectados por uma VPN privada (Tailscale), executando containers descritos em Terraform a partir de um inventário Ansible. O paralelismo é demonstrado em duas dimensões — dados (ingestão em duas filas com chunk-workers escaláveis) e tarefas (query-workers replicados consumindo de uma fila comum). A engenharia de contexto é explícita e versionada; a observabilidade é completa (métricas, logs, dashboards) e a tolerância a falhas atravessa quatro camadas (retry, DLQ, degraded mode, fallback estrutural).

O resultado mais valioso para a disciplina, mais do que os números do smoke ou a topologia funcionando, foi articular um **resultado negativo bem caracterizado** (a não-adesão do qwen2.5:7b ao function calling sob contexto RAG denso) — um achado isolado por diagnóstico controlado, com hipótese articulada e alavancas remanescentes mapeadas para trabalho futuro. Engenharia de contexto, no fim, não é sobre fazer o modelo sempre se comportar; é sobre saber **quando e como** ele se comporta, e ter um caminho secundário pronto para quando não se comportar.

Apêndices

- **A. Prompts** — prompts/ com frontmatter YAML; versão corrente v0.2.3-b2.
- **B. Uso de IA** — docs/USO_DE_IA.md (inclui entrada de 2026-05-24 sobre suspensão de liberada do §3.4 para esta entrega).
- **C. Runbooks** — docs/setup-tailscale.md, docs/setup-gpu-pcl.md.
- **D. Evidências** — data/b1-smoke.txt, data/b2-smoke.txt, data/b2-metrics.txt, data/b2-filas.png. Gráficos do B4 pendentes.
- **E. Relatórios (8.4)** — docs/relatorios_aprendizagem/{davi_cavalcante,joao_miguel,pablo_abdon}.